

Добавление в ClickHouse поддержки constraints Курсовая работа

Глеб Новиков, 3 курс ВШЭ БПМИ

Алексей Миловидов, руководитель группы разработки ClickHouse

Факультет компьютерных наук 01.03.02 «Прикладная математика и информатика»

6 июня 2019 г.

Введение



Ограничения в БД

Ограничения (constraints) — набор обязательных правил для данных, находящихся в таблице базы данных. Например:

- DEFAULT some_default_value
- NOT NULL
- UNIQUE [(column_1[, column_2])]
- CHECK expression
- ...

Введение

Ограничения в БД



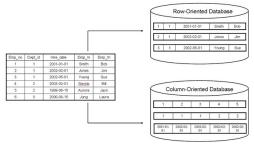
Таблица продуктов с примером объявления разных типов ограничений:

```
CREATE TABLE products (
   id integer PRIMARY KEY,
   shop_id integer REFERENCES shops,
   product text NOT NULL,
   price numeric CHECK (price > 0)
);
```



Что это и зачем?

• Данные хранятся не по строкам, а по колонкам:





Что это и зачем?

• Данные хранятся не по строкам, а по колонкам:

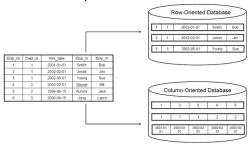


• Используются для хранения сырых неаггрегированных данных (например логов)



Что это и зачем?

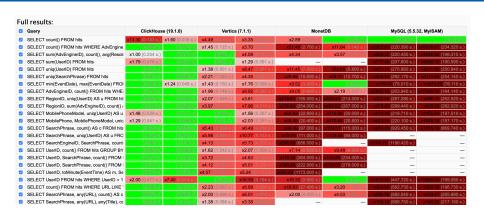
• Данные хранятся не по строкам, а по колонкам:



- Используются для хранения сырых неаггрегированных данных (например логов)
- В основном используются для аггрегационных online запросов (возможно, приближённых)

R

Производительность ClickHouse



Бенчмарки ClickHouse и других колоночных БД

https://clickhouse.yandex/benchmark.html

Ограничения в колоночных БД



Почти

не нужны:

- UNIQUE
- FOREIGN KEY

Ограничения в колоночных БД



Почти

не нужны:

- UNIQUE
- FOREIGN KEY

Нужны:

- PRIMARY KEY
- DEFAULT
- NOT NULL
- CHECK

Задача



Формулировка требований

Peanusoвamь поддержку NOT NULL и CHECK ограничений (на самом деле достатточно только CHECK, так как существуют функции <code>isNulluisNotNull</code>).

Вместе с объявлением нужны все сопутствующие возможности: отдельное добавление и удаление ограничений, а так же исключение при обработке некорректных данных в процессе вставки.



Запрос объявления ограничений

Конвеер выполнения запроса



. . .

- . executeQuery
 - . setting up query context and settings
 - . parseQuery
 - . query parsing to AST
 - . InterpreterFactory::get
 - . choose interpreter based on AST type and $\ensuremath{\mathsf{meta}}$
 - . interpreter.execute()
 - . storages and meta changes
 - . pre-processing of data streams
 - . processing of data streams
 - . query logging etc

Конвеер выполнения запроса



. . .

- . executeQuery
 - . setting up query context and settings
 - * > parseQuery
 - * > query parsing to AST
 - * > InterpreterFactory::get
 - * > choose interpreter based on AST type and meta
 - * > interpreter.execute()
 - \star > storages and meta changes
 - * > pre-processing of data streams
 - * > processing of data streams
 - . query logging etc

Архитектура



Затронутые библиотеки:

- > src
 - . DataStreams
 - . Interpreters
 - . Parsers
 - . Storages (for data and meta data)
 - . [Core, Client, IO, ...]



CREATE запрос, парсеры



СПЕАТЕ запрос, парсеры

1. Parsers

1.1 ASTConstraintDeclaration — хранение мета-данных ограничений из запроса



CREATE запрос, парсеры

- 1.1 ASTConstraintDeclaration хранение мета-данных ограничений из запроса
- 1.2 Правки ASTColumns для хранения ограничений и базовой работы с ними



CREATE запрос, парсеры

- 1.1 ASTConstraintDeclaration хранение мета-данных ограничений из запроса
- 1.2 Правки ASTColumns для хранения ограничений и базовой работы с ними
- 1.3 ParserConstraintDeclaration парсер объявления ограничения (строки)



CREATE запрос, парсеры

- 1.1 ASTConstraintDeclaration хранение мета-данных ограничений из запроса
- 1.2 Правки ASTColumns для хранения ограничений и базовой работы с ними
- 1.3 ParserConstraintDeclaration парсер объявления ограничения (строки)
- 1.4 Правки ParserTablePropertyDeclaration добавление парсинга ограничения по ключу CONSTRAINT



CREATE запрос, хранение и интепретация

2. Storages



CREATE запрос, хранение и интепретация

2. Storages

2.1 ConstraintsDescription



CREATE запрос, хранение и интепретация

2. Storages

- 2.1 ConstraintsDescription
- **2.2** Правки IStorage добавление работы с ConstraintsDescription



CREATE запрос, хранение и интепретация

2. Storages

- 2.1 ConstraintsDescription
- 2.2 Правки IStorage добавление работы с ConstraintsDescription
- 2.3 Добавление поддержки в MergeTree* структуры



CREATE запрос, хранение и интепретация

- 2. Storages
 - 2.1 ConstraintsDescription
 - 2.2 Правки IStorage добавление работы с ConstraintsDescription
 - 2.3 Добавление поддержки в MergeTree* структуры
- 3. Interpreters



CREATE запрос, хранение и интепретация

2. Storages

- 2.1 ConstraintsDescription
- 2.2 Правки IStorage добавление работы с ConstraintsDescription
- 2.3 Добавление поддержки в MergeTree* структуры

Interpreters

3.1 Добавление работы с ограничениями в InterpreterCreateQuery



INSERT запрос, потоки данных и интерпретация

1. DataStreams



INSERT запрос, потоки данных и интерпретация

1. DataStreams

1.1 CheckConstraintsBlockOutputStream — проверка ограничений на блоке данных в момент его записи



INSERT запрос, потоки данных и интерпретация

1. DataStreams

- 1.1 CheckConstraintsBlockOutputStream проверка ограничений на блоке данных в момент его записи
 - + Columns/ColumnsCommon: добавлена функция memoryIsByte, переписана memoryIsZero



INSERT запрос, потоки данных и интерпретация

- 1. DataStreams
 - 1.1 CheckConstraintsBlockOutputStream проверка ограничений на блоке данных в момент его записи
 - + Columns/ColumnsCommon: добавлена функция memoryIsByte, переписана memoryIsZero
- 2. Interpreters



INSERT запрос, потоки данных и интерпретация

1. DataStreams

- 1.1 CheckConstraintsBlockOutputStream проверка ограничений на блоке данных в момент его записи
 - + Columns/ColumnsCommon: добавлена функция memoryIsByte, переписана memoryIsZero

2. Interpreters

2.1 Обёртка в CheckConstraintsBlockOutputStream потока блоков данных





1. Parsers

1.1 Правки ASTAlterCommand — добавление нового типа команд, хранение AST ограничений



- 1.1 Правки ASTAlterCommand добавление нового типа команд, хранение AST ограничений
- 1.2 Правки в ParserAlterCommand парсинг нового типа команд



- 1.1 Правки ASTAlterCommand добавление нового типа команд, хранение AST ограничений
- 1.2 Правки в ParserAlterCommand парсинг нового типа команд
- 2. Storages



1. Parsers

- 1.1 Правки ASTAlterCommand добавление нового типа команд, хранение AST ограничений
- 1.2 Правки в ParserAlterCommand парсинг нового типа команд

2. Storages

2.1 Правки AlterCommand — реализация добавления и удаления ограничений



1. Parsers

- 1.1 Правки ASTAlterCommand добавление нового типа команд, хранение AST ограничений
- 1.2 Правки в ParserAlterCommand парсинг нового типа команд

2. Storages

- 2.1 Правки AlterCommand реализация добавления и удаления ограничений
- 2.2 Прокидвание ConstraintsDescription во всех alter и alterTable методах разных Storages





Объявление и удаление constraints

Примеры

R

Объявление и удаление constraints

```
ALTER TABLE products
DROP CONSTRAINT non_empty_title;
```

ALTER TABLE products

DROP CONSTRAINT price_above_zero;

ALTER TABLE products

ADD CONSTRAINT non_empty_title

CHECK NOT empty(title);

ALTER TABLE products

ADD CONSTRAINT price_above_zero

CHECK price > 0;

Примеры



Исключения при нарушении constraints

```
clickhouse:) INSERT INTO products VALUES (1, 2, '', 1.1);

Code: 49. DB::Exception: Constraint non_empty_title
is not satisfied, constraint expression: NOT empty(title).

clickhouse:) INSERT INTO products VALUES (1, 2, 'a', 0);

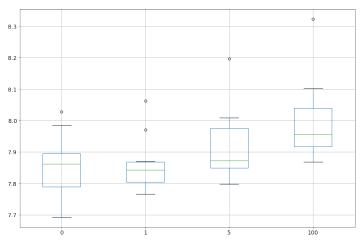
Code: 49. DB::Exception: Constraint price_above_zero
is not satisfied, constraint expression: price > 0.
```

Бенчмарк

R

Разное количество ограничений на одной таблице

1 млн. строк, \sim 130 колонок, 854 МБ.



Время вставки датасета в сек.



Что было сделано?

1. Изучены существующие constraints в различных базах данных

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse

Код доступен в РК # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:
 - 4.1 Объявление ограничений

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:
 - 4.1 Объявление ограничений
 - 4.2 Добавление и удаление ограничений

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:
 - 4.1 Объявление ограничений
 - 4.2 Добавление и удаление ограничений
 - 4.3 Проверка ограничений на вставляемые данные

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:
 - 4.1 Объявление ограничений
 - 4.2 Добавление и удаление ограничений
 - 4.3 Проверка ограничений на вставляемые данные
- 5. Написаны тесты запросов и исключений на вставку

Код доступен в PR # 5273 по ссылке

R

Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:
 - 4.1 Объявление ограничений
 - 4.2 Добавление и удаление ограничений
 - 4.3 Проверка ограничений на вставляемые данные
- 5. Написаны тесты запросов и исключений на вставку
- 6. Проведён простой бенчмарк, потеря около 2%

Код доступен в PR # 5273 по ссылке



Что было сделано?

- 1. Изучены существующие constraints в различных базах данных
- 2. Изучены особенности колоночных БД, в частности ClickHouse
- 3. Изучена необходимая часть архитектуры ClickHouse
- 4. Реализовано:
 - 4.1 Объявление ограничений
 - 4.2 Добавление и удаление ограничений
 - 4.3 Проверка ограничений на вставляемые данные
- 5. Написаны тесты запросов и исключений на вставку
- 6. Проведён простой бенчмарк, потеря около 2%
- 7. Расширена документация, добавлены описания constraints

Код доступен в PR # 5273 по ссылке



Что дальше?

1. Подробное тестирование на всех движках таблиц



- 1. Подробное тестирование на всех движках таблиц
- 2. Более подробные исключения: строка в данных, значения в строке



- 1. Подробное тестирование на всех движках таблиц
- 2. Более подробные исключения: строка в данных, значения в строке
- 3. Команда на проверку ограничений по существующим данным в таблице



- 1. Подробное тестирование на всех движках таблиц
- 2. Более подробные исключения: строка в данных, значения в строке
- 3. Команда на проверку ограничений по существующим данным в таблице
- 4. Оптимизации запросов с использованием информации из ограничений



- 1. Подробное тестирование на всех движках таблиц
- 2. Более подробные исключения: строка в данных, значения в строке
- 3. Команда на проверку ограничений по существующим данным в таблице
- 4. Оптимизации запросов с использованием информации из ограничений
- 5. ...

Спасибо за внимание!



Добавление в ClickHouse поддержки constraints

Глеб Новиков, 3 курс ВШЭ БПМИ

Алексей Миловидов, руководитель группы разработки ClickHouse

Факультет компьютерных наук 01.03.02 «Прикладная математика и информатика»

6 июня 2019 г.