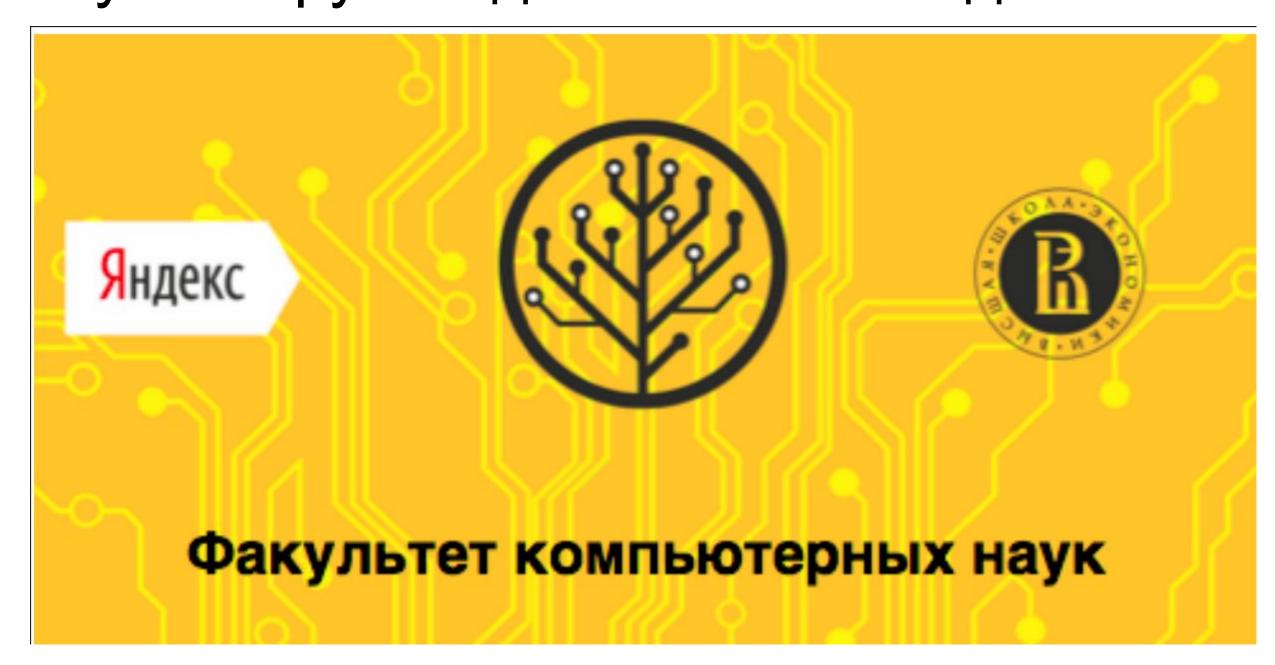
Умные алгоритмы обработки строк в ClickHouse

Кутенин Данила Михайлович 155 Научный руководитель: Миловидов Алексей



Область и цели

- Все используют строки. Везде. Всегда. В любых рантайм сервисах.
- ClickHouse заточен под скорость.
- Поиск, обработка, разжатие -- всё это важно. Очень.

Задачи

- Поиск подстрок во всех ипостасях, hyperscan
- Приближенный поиск
- Строки, закодированные в UTF-8
- Оптимизация SSE, в том числе и под другими платформами
- Ускорение кодека LZ4 (не успеем поговорить)
- Аллокации кешей (не успеем поговорить)

Задачи. Что не вошло в диплом

- Проверка на валидность UTF-8, toValidUTF8
- Оптимизация concat функции
- Внедрение format функции
- Бенчмарки на все функции, которые внедрили
- Стресс и fuzzy тестирование всех функций, которые внедрили
- Внедрение нового аллокатора
- Упрощение SSE кода для поиска подстрок
- Фиксы external dictionaries обработки строк
- Переезд на GCC9, внедрение libc++, сравнение библиотек
- And many more...

Строки

Любая последовательность байт в алфавите Σ.

Строки в ClickHouse

ColumnString. Chars + Offsets.

16 байтовый паддинг до Chars и 15 байтовы паддинг после. Безопасное чтение 16 байтового регистра.

Строки в ClickHouse

ColumnFixedString. Chars + FixedConstant N.

- 16 байтовый паддинг до Chars и 15 байтовы паддинг после. Безопасное чтение 16 байтового регистра.
- Также ColumnConst с типом String.
- Ещё LowCardinality (но это тема для отдельного разговора).

Поиск. Определения.

- haystack (англ. сено) -- строка, в которой мы ищем.
- needle (англ. иголка) -- строка (или регулярное выражение), по которой мы ищем.

Один needle, один haystack

- 1. Knuth-Morris-Pratt
- 2. Boyer-Moore
- 3. Boyer-Moore-Horspool
- 4. BNDM (Backward Nondeterministic Dawg)
- 5. Two-way (memmem)
- 6. Rabin-Karp
- 7. Поиск по индексу
- 8. ..

Mного needle, один haystack

- 1. Aho-Corasick
- 2. Поиск по индексу
- 3. Rabin-Karp(?)

Что использует ClickHouse?

Ничего из вышеперечисленного Но я честно попробовал все варианты

Volnitsky algorithm



```
SELECT count()
FROM hits_100m_single
WHERE URL LIKE '%yandex%'
SETTINGS max_threads = 1

-count()
18401331
```

1 rows in set. Elapsed: 5.337 sec. Processed 100.00 million rows, 9.38 GB (18.74 million rows/s., 1.76 GB/s.)

- 1. Сохраняем в хэш-таблицу с открытой адресацией оффсеты всех биграмм (два подряд идущих байта) строки needle (с конца).
- 2. Идём по haystack с шагом needle.size() 1, просматриваем соответствующую биграмму в хэш-таблице и сравниваем куски памяти на равенство (темстр или что-то похитрее).
- 3. Шаг needle.size() 1 гарантирует, что если есть вхождение, мы всегда просмотрим хотя бы одну биграмму этого вхождения.
- 4. Добавление с конца гарантирует поиск первого вхождения (рассматриваем сначала большие оффсеты, потом маленькие).

Пусть будет строка haystack – **abacabaac** и needle равна **aaca**. Хэш-таблица $\{aa \rightarrow 0, ac \rightarrow 1, ca \rightarrow 2\}$.

```
0 1 2 3 4 5 6 7 8 9
a b a c a b a a c a
   ^ - курсор изначальный здесь
0 1 2 3 4 5 6 7 8 9
a b a c a b a a c a
 a a c a
0 1 2 3 4 5 6 7 8 9
abacabaaca
         ^ - курсор теперь здесь
0 1 2 3 4 5 6 7 8 9
abacabaaca
               ^ - курсор теперь здесь
```

Нашли совпадение.

Реализация в ClickHouse





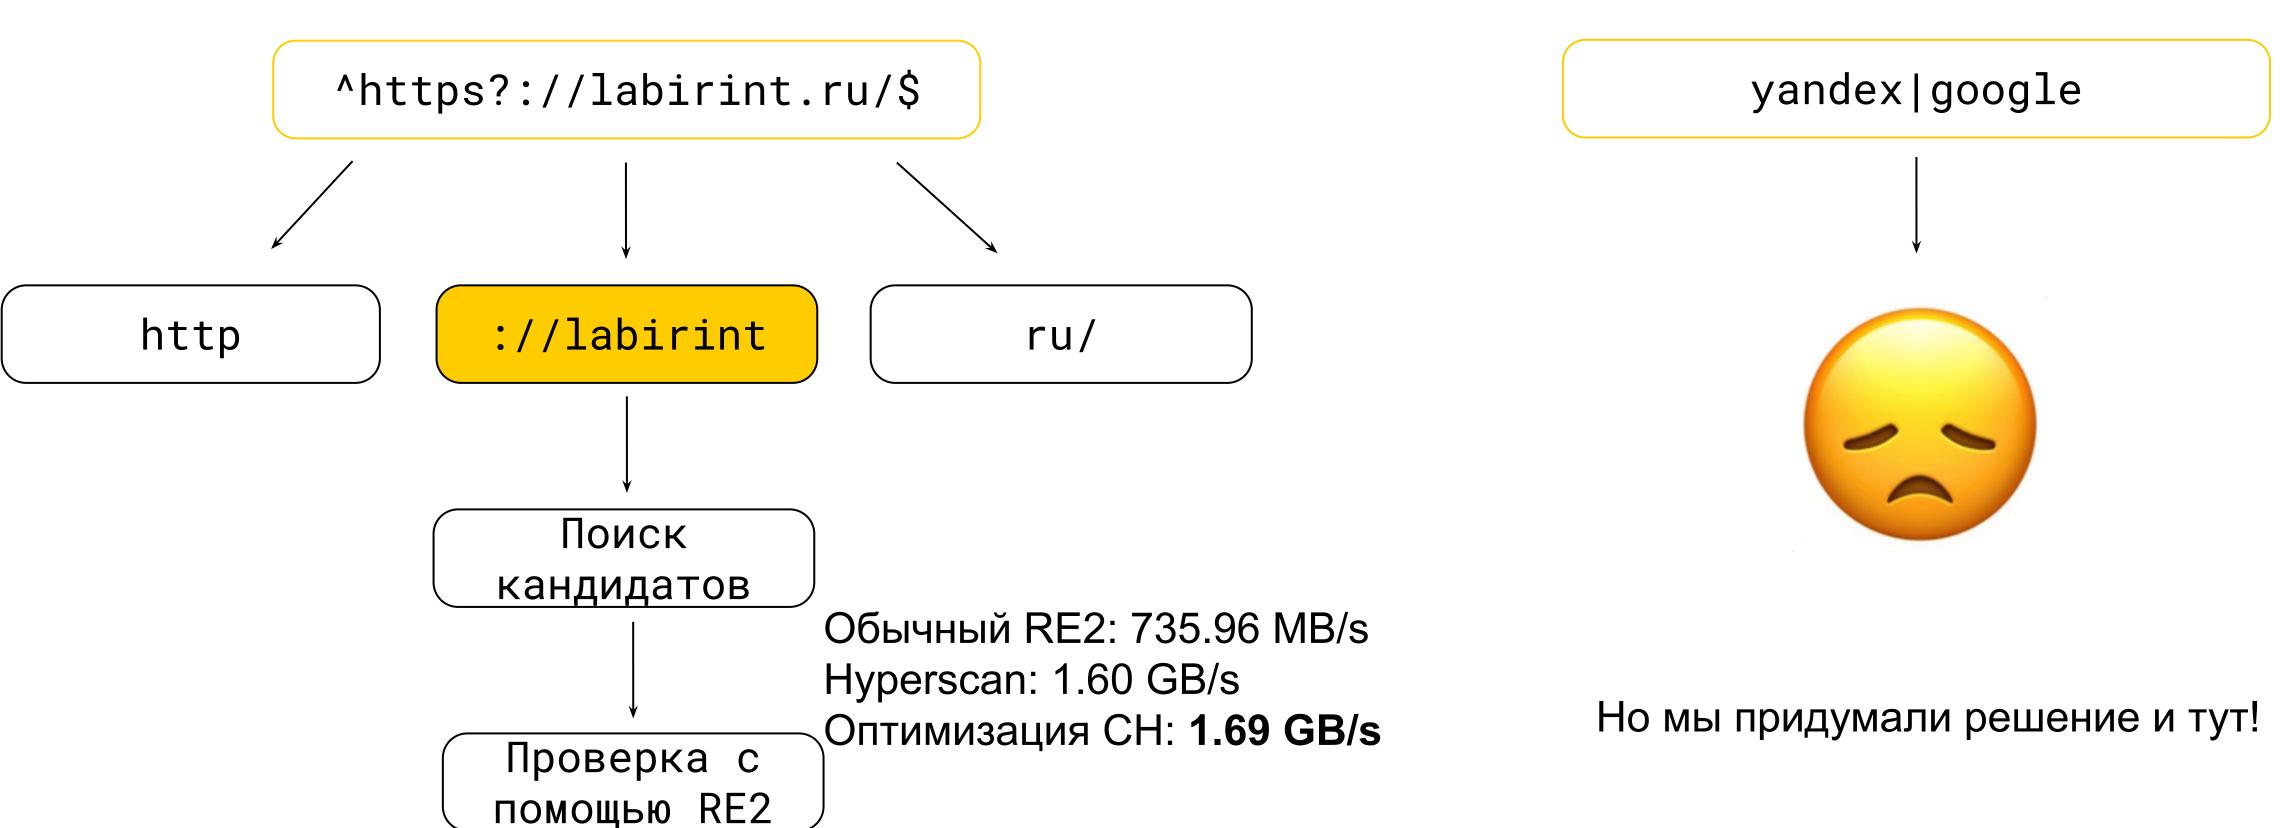
| Алгоритм/Запрос | SELECT sum(position(URL, 'google')) FROM hits_100m_single settings max_threads=1 | SELECT count() FROM hits_100m_single WHERE URL LIKE "%metrika%" settings max_threads=1 | SELECT sum(position(URL, 'yandex')) FROM hits_100m_single settings max_threads=1 | SELECT SearchPhrase, any(URL), any(Title), count() AS c, uniq(UserID) FROM hits_100m_single WHERE (Title LIKE '%Яндекс%') GROUP BY SearchPhrase ORDER BY c DESC LIMIT 10 settings max_threads=1 |
|-----------------|--|--|--|--|
| memmem | 655 Mb/s | 710 MB/s | 637 MB/s | 578 MB/s |
| BM | 865 MB/s | 940 MB/s | 780 MB/s | 600 MB/s |
| BMH | 920 MB/s | 930 MB/s | 790 MB/s | 687 MB/s |
| KMP | 600 MB/s | 653 MB/s | 580 MB/s | 540 MB/s |
| Volnitsky | 1.66 GB/s | 1.80 GB/s | 1.56 GB/s | 880 MB/s |



Поиск. Где используется алгоритм.

position(s0, s1), -UTF8, -CaseInsensitive, -CaseInsensitiveUTF8 LIKE '%somestring%'

Оптимизация поиска регулярных выражений, в т.ч. LIKE



MultiVonitsky algorithm

```
SELECT sum(multiSearchAny(URL, ['yandex', 'google', 'yahoo']))
FROM hits_100m_single
SETTINGS max_threads = 1

__sum(multiSearchAny(URL, ['yandex', 'google', 'yahoo']))______
18441259

1 rows in set. Elapsed: 7.747 sec. Processed 100.00 million rows, 9.38 GB (12.91 million rows/s., 1.21 GB/s.)
```

- 1. Сохраняем в хэш-таблицу с открытой адресацией оффсеты и id строки всех биграмм (два подряд идущих байта) всех строк needle (с конца).
- 2. Идём по haystack с шагом step=min(needle[i].size() 1) for all i, просматриваем соответствующую биграмму в хэш-таблице и сравниваем куски памяти.
- 3. Шаг **step** гарантирует, что если есть вхождение, мы всегда просмотрим хотя бы одну биграмму этого вхождения.

| | Multi Volnitsky | Volnitsky n pas | Aho Corasick | RE2 | Hyperscan |
|---|--------------------|--------------------|--------------|-------------|-------------|
| 'yandex', 'google' | 1.49 GB/s | 1.18 GB/s | 851.32 MB/s | 329.39 MB/s | 788.21 MB/s |
| 'yandex', 'google', 'yahoo', 'pikabu' | 1.27 GB/s | 762.13 MB/s | 780.65 MB/s | 303.58 MB/s | 748.03 MB/s |
| 'yandex', 'google', 'http' | 1.69 GB/s | 1.00 GB/s | 1.19 GB/s | 773.28 MB/s | 626.18 MB/s |
| 'Honda', 'Хонд', 'HONDA' | 900.07 MB/s | 741.97 MB/s | 730.20 MB/s | 168.26 MB/s | 814.30 MB/s |
| 'yandex', 'google', 'facebook', 'wikipedia', 'reddit' | 1.22 GB/s | 677.39 MB/s | 813.57 MB/s | 267.00 MB/s | 757.16 MB/s |
| 'news.ngs.ru', 'she.ngs.ru', 'afisha.ngs.ru', 'business.ngs.ru', '//ngs.ru/', '//m.ngs.ru/' | 1.35 GB/s | 681.91 MB/s | 890.13 MB/s | 220.24 MB/s | 850.83 MB/s |

| | Multi Volnitsky | Volnitsky n pas | Aho Corasick | RE2 | Hyperscan |
|---|--------------------|--------------------|--------------|-------------|-------------|
| 'newFlat=YES', 'newbuilding', 'siteId=', 'novostrojka', 'nb.phone.show', 'nb.show', 'pik/' | 906.08 MB/s | 584.09 MB/s | 737.94 MB/s | 252.77 MB/s | 724.39 MB/s |
| 'kvartiry', 'nedvizhimost', 'kommercheskaya_nedvizhimost', 'garazhi_i_mashinomesta', 'doma_dachi_kottedzhi', 'zemelnye_uchastki', 'komnaty', 'nedvizhimost_za_rubezhom' | 1.05 GB/s | 644.00 MB/s | 757.43 MB/s | 250.75 MB/s | 775.68 MB/s |
| 'ут', 'утк', 'утко', 'утконос', 'enrjyjc', 'utkonos', 'enrjyjc', 'www', 'http', 'enrfyjc', 'гелщтщы' | 500.44 MB/s | 254.45 MB/s | 453.21 MB/s | 134.45 MB/s | 532.78 MB/s |
| 'бэбиблок', 'бэбиблог', 'бебиблок', 'бебиблог', 'blog', 'беби блог', 'бэби блог', 'бэби блог', 'бөби блог', 'бейбиблог', 'бейбиблог', 'бейбиблог', 'бэби блок', 'бэбибло', 'бебиб', 'бебибло' | 106.74 MB/s | 74.21 MB/s | 394.98 MB/s | 139.00 MB/s | 511.22 MB/s |

| | Multi Volnitsky | Volnitsky n pas | Aho Corasick | RE2 | Hyperscan |
|--|--------------------|--------------------|--------------|-------------|-------------|
| 'fitnes-kluby', 'sportivnoe-oborudovanie-atributika', 'krytye-sportivnye-ploshchadki', 'pejntbol-strajk-i-hard-bol', 'strelkovye-kluby-tiry', 'sportivnye-organizatsii', 'basseyny-plavatelnye', 'otkrytye-sportivnye-ploshchadki-bazy' , 'gornolyzhnye-sklony', 'pryzhki-s-parashyutom', 'sportivnye-sektsii', 'yakht-kluby', 'joga-centry-i-instruktory', 'bukmekerskie-kontory', 'skalolazanie-voskhozhdenie-v-gory', 'fekhtovalnye-kluby', 'drugoj-sport-i-fitnes', 'boevye-iskusstva' | 889.12 MB/s | 198.91 MB/s | 640.33 MB/s | 195.09 MB/s | 642.42 MB/s |

| | Multi Volnitsky | Volnitsky n pas | Aho Corasick | RE2 | Hyperscan |
|---|--------------------|--------------------|--------------|-------------|-------------|
| 'chelyabinsk.74.ru', 'doctor.74.ru', 'transport.74.ru', 'm.74.ru', '//74.ru/', 'chel.74.ru', 'afisha.74.ru', 'diplom.74.ru', 'chelfin.ru', '//chel.ru', 'chelyabinsk.ru', 'cheldoctor.ru', '//mychel.ru', 'cheldiplom.ru', '74.ru/video', 'market', 'poll', 'mail', 'conference', 'consult', 'contest', 'tags', 'feedback', 'pages', 'text' | 418.14 MB/s | 230.13 MB/s | 413.58 MB/s | 183.31 MB/s | 639.61 MB/s |
| 'p17266p66989p97b7', 'p17266p66988p285b', 'p17266p66986pa4e8', 'p15926p65809pbab6', 'p15926p65810p2672', 'p15926p65811p9afa', 'p15926p65812p97e3', 'p15926p65813pd214', 'p15926p65813pd214', 'p15926p65815p350b', 'p15926p65816pe52c', 'p15926p65814p0cc9', 'p15926p65817p4cea', 'p15926p65818p9b20', 'p15926p65860p4435', 'p15926p65861p1f1e', 'p15926p65862p6f5b', 'p15926p65864pef1c', 'p15926p64433p9fca', 'p15926p64435p9eb7', 'p15926p64436p5e2c', 'p14762p59496p5de8', 'p14762p67782pfc4a' | 1.20 GB/s | 330.57 MB/s | 990.87 MB/s | 524.60 MB/s | 1.10 GB/s |
| | | | | | 18 |

| | Multi Volnitsky | Volnitsky n pas | Aho Corasick | RE2 | Hyperscan |
|--|--------------------|--------------------|--------------|-------------|-------------|
| 'вуман', 'вумен ру женский журнал', 'вумен форум', 'вуманжурнал ру',' воман', 'www.woman.ru', 'вуман ру', 'woman ru', 'женский журнал', 'форум вумен', 'devty', 'вумен.ру', 'вумен ру форум', 'вуманжурнал', 'женский форум', 'женский журнал вумен', 'woman форум', 'devty he', 'вуман.ру', 'женский форум вумен', 'women.ru женский сайт', 'форум вумен ру', 'вум', 'сайт вумен', 'воменс. ру', 'devfy', 'вомен', 'woman.ru журнал', 'woman.ru форум', 'вуменру',' вуман форум', 'цщьфтюкг', 'devfy he', 'wom', 'вумен форум новое', 'вумен форум новые', 'вумен форум вуман | 42.19 MB/s | 31.10 MB/s | 380.23 MB/s | 140.07 MB/s | 441.12 MB/s |

- До 10-15 строк MultiVolnitsky обыгрывает всех (97% запросов).
- Деградация при большом количестве маленьких или похожих строк.
- Ускорение от большой минимальной длины строки.

Новые фичи ClickHouse (19.5)

- multiSearchAny -- есть ли хоть одно вхождение из needle
- multiSearchFirstPosition -- самая левая позиция haystack, найденного какимнибудь needle
- multiSearchFirstIndex -- самый левый индекс найденного needle
 - multiSearchAllPositions -- поиск всех первых позиций
 - Суффиксы -UTF8, -CaseInsensitive, -CaseInsensitiveUTF8

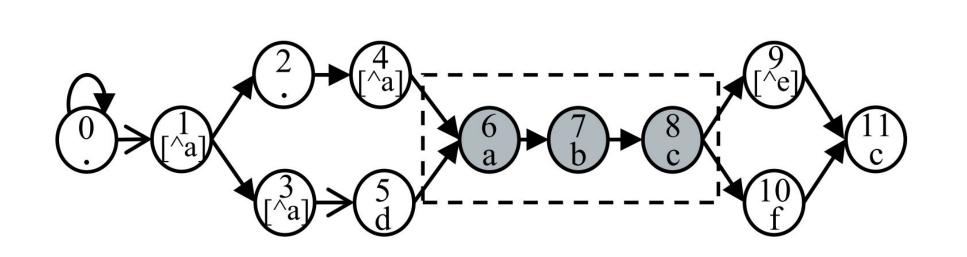
Все алгоритмы используют MultiVolnitsky

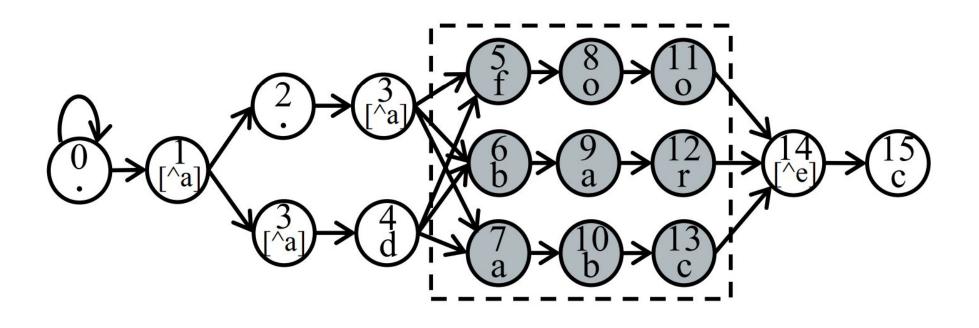
Сравнение алгоритмов для поиска множества регулярных выражений

Добавили поддержку Hyperscan.

USENIX Статья 2019 года. 5 версия вышла во время наших исследований. Более 12 лет разработки. Мы его смогли обогнать на 97% обычных текстовых запросах. Имеет ряд ограничений. Длина строки должна быть меньше 2^32. Потребляет недокументированное количество памяти.

Зато быстрый, как мы уже видели.





| | RE2 | Hyperscan |
|--|-------------|-------------|
| '/t[0-9]+-', '/questions/7{9}[0-9]+' | 565.51 MB/s | 743.88 MB/s |
| 'ножниц.*вырубн', 'ножниц.*рычажн', 'ножниц.*гильотин' | 155.72 MB/s | 505.31 MB/s |
| 'f[ae]b[ei]rl', 'ф[иаэе]б[еэи][рпл]', 'афиукд', 'a[ft],th', '^ф[аиеэ]?б?[еэи]?\$', 'берлик', 'fab', 'фа[беьв]+e?[рлко]' | 183.32 MB/s | 422.65 MB/s |
| '/questions/q*', '/q[0-9]*/', '/questions/[0-9]*' | 524.58 MB/s | 936.12 MB/s |
| '//ngs.ru/\$', '//m.ngs.ru/\$', '//news.ngs.ru/\$', '//m.news.ngs.ru/\$', '//ngs.ru/\\?', '//m.ngs.ru/\\?', '//news.ngs.ru/\\?', '//m.news.ngs.ru/\\?' | 543.41 MB/s | 619.82 MB/s |
| '[ми][аеэпви][нм][асзи][иус]*', '[mn][aeauo][nm]s[yyi]*', 'ru', 'v[ft']v[cp][be]', 'www', 'ьфьын', 'маиси', 'mam', 'amsy', 'маммси', 'амси', 'vfvc' | 141.17 MB/s | 463.87 MB/s |

Новые фичи ClickHouse (19.5)

- multiMatchAny -- возвращает один, если хотя бы одно регулярное выражение подошло под haystack и ноль иначе.
- multiMatchAnyIndex -- возвращает индекс любого вхождения регулярного выражения в haystack

В функциях используется честный hyperscan.

- Хотим искать похожие строки между собой. (яндекс ~ индекс)
 Надо определиться с метрикой. Левенштейн -- квадратично тяжело и "сильно"
 легче быть не может.
- Тем не менее, сделали подсказки опечаток в запросах по Левенштейну.

- Есть расстояние Хэмминга. Есть алгоритм O(|Σ|n log n).
- 1. Пусть есть две строки размера n и m, где m < n. Мы хотим найти из всех наложений минимальное отличающееся. Будем считать массив отличающихся и выбирать наименьшее число.
- 2. Можно посчитать ответ посимвольно через битовые маски, где 1 -- есть символ A, а 0 -- нет символа A.
- 3. Далее это скалярные произведения таких битовых масок. Это можно посчитать через Быстрое Преобразование Фурье за O(n log n) (скалярные произведения очень похожи на свёртки).
- Не самый практичный способ, так как |Σ| может быть до 256. Даже 30 уже много.

- 1. Посмотрели немного в биоинформатику, нашли n-граммное расстояние.
- 2. Сделали ngramDistance (19.5, фиксы в 19.8)
- 3. Чем ближе к нулю возвращаемое значение, тем строки более похожи.
- 4. По факту это 4 граммное расстояние (симметрическая нормализованная на количество n-грамм разность между мультимножествами двухбайтных CRC32 хэшей).

```
SELECT DISTINCT SearchPhrase
FROM hits_100m_single
ORDER BY ngramDistance(SearchPhrase, 'clickhouse') ASC
LIMIT 20

SearchPhrase
tickhouse
clockhouse
house
clickhomecyprus
```

1click

uhouse

madhouse

icehouse

doghouse

funhouse

dollhouse

houses.ru

bighouses

uhouse.ru

tic house

dog house

luk house

house m.d

teakhouse.ru

teakhouse.com

Реализация ngramDistance



- 1. Мы будем использовать 4-граммы и хэшировать их в 16 битное число с помощью инструкции crc32q, а также заведём 16-битный массив из 2^16 элементов, куда будем складывать абсолютную разницу количества этих хэшей у haystack и needle.
- 2. Мы заведём буффер из 19 кодовых точек, чтобы можно было копировать 3 кодовые точки из конца в начало и читать по 16 кодовых точек в буффер. Такие числа позволяют быстрее читать данные из-за SIMD инструкций, а именно получается по 13 кодовых точек за раз;

Реализация ngramDistance

```
|a0|a1|a2|a3|a4|a5|a6|a7|a8|a9|a10|a11|a12|a13|a14|a15|a16|a17|a18|
Мы копируем ^^^^^^^^^^^^
эти кодовые точки в начало
```

- Строки длины больше 2^15 никогда не похожи друг на друга
- С наивной имплементации за 150 MB/s мы смогли получить 250 MB/s на один поток

- ngramDistance(haystack, needle)
- -UTF8, -CaseInsensitive, -CaseInsensitiveUTF8

CaseInsensitiveUTF8 имеет грязный хак -- работает только для русских и английских букв. Мы зануляем 5-й бит каждого байта и нулевой бит нулевого байта, если байтов больше одного.

ngramSearch(haystack, needle) (19.8) -- приближенный поиск подстрок, идея та же. Пока в экспериментальном режиме -- надо доделать мелочь.

- multiFuzzyMatchAny(haystack, distance, [pattern_1, ..., pattern_n])
 - multiMatchAnyIndex(haystack, distance, [pattern_1, ..., pattern_n])

Это приближённый поиск hyperscan. Создаются distance+1 конечных автоматов (слои) и проводятся соответствующие переходы между соседними слоями, означающие "штраф".

Работает долго, так как автомат усложняется и добавляются eps-переходы. Нет UTF-8 поддержки.

UTF-8 кодировка

| Кодовые точки | Первый байт | Второй байт | Третий байт | Четвёртый байт |
|----------------------------|-------------|--------------|-------------|----------------|
| $U+0000 \dots U+007F$ | 007F | | | |
| $U+0080 \dots U+07FF$ | C2DF | 80BF | | |
| U+0800U+0FFF | E0 | A0 BF | 80BF | |
| $U+1000\ldots U+CFFF$ | E1EC | 80BF | 80BF | |
| U+D0000U+D7FF | ED | 80 9F | 80BF | |
| $U+E000\ldots U+FFFF$ | EEEF | 80BF | 80BF | |
| U+10000 U+3FFFF | F0 | 90 BF | 80BF | 80BF |
| $U+40000\ldots U+FFFFF$ | F1F3 | 80BF | 80BF | 80BF |
| $U+1000000\ldots U+10FFFF$ | F4 | 80 8F | 80BF | 80BF |

UTF-8 кодировка. Вычисление длины

```
1 inline size t countCodePoints(const UInt8 * data, size t size)
2~ {
       size t res = 0;
       const auto end = data + size;
   #ifdef SSE2
       constexpr auto bytes sse = sizeof( m128i);
       const auto src end sse = data + size / bytes sse * bytes sse;
 8
9
       const auto threshold = mm set1 epi8(0xBF);
10
11
12~
       for (; data < src end sse; data += bytes sse)</pre>
          res += builtin popcount( mm movemask epi8(
13
              14
15~
   #endif
16
17
       for (; data < end; ++data) /// Skip UTF-8 continuation bytes.</pre>
          res += static cast<Int8>(*data) > static cast<Int8>(0xBF);
18
19
20
       return res;
21 }
```

UTF-8 кодировка. Вычисление длины

```
Вход:
0x00 0xE0 0x80 0xF4 0x80 0xBF 0xBF 0x7A 0xEE 0x82 0x8A 0xE1 0x80 0x80 0x0E 0x0A
_mm_cmpgt_epi8 (pcmpgtb)
_mm_movemask_epi8 (pmovmskb)
            0b1101000010010011
                 __builtin_popcount (popcnt)
```

UTF-8 кодировка. Проверка на валидность

isValidUTF8(string) (19.7) -- проверяет, является ли строка корректно UTF-8 закодированной

Наивная имплементация выдавала 900 MB/s. Мы, конечно, хотим больше.

Использовали алгоритм "диапазонов" за основу и адаптировали под нас. Source: https://github.com/cyb70289/utf8/

Соптимизировали до 1.22 GB/s

Последние приятности (после диплома)

- toValidUTF8(string) -- заменяем некорректные символы UTF-8 на символ `�`. Все идущие подряд некорректные символы схлопываются в один заменяющий символ (19.8). No rocket science.
- format(pattern, strings...) -- новая функция (19.8). Сильно SSE оптимизирована.
- concat(strings...) -- соптимизировали до 40% через format (19.8).

```
SELECT format('{1} {0} {1}', 'World', 'Hello')

Format('{1} {0} {1}', 'World', 'Hello')

Hello World Hello

SELECT format('{} {}', 'Hello', 'World')

Format('{} {}', 'Hello', 'World')

Hello World
```

Умные алгоритмы обработки строк в ClickHouse

Данила Кутенин



HighLoad **
Siberia 2019

Профессиональная конференция для разработчиков высоконагруженных систем



Яндекс

Спасибо

Данила Кутенин

anlark@yandex-team.ru

② @Danlark